

# 基于自适应近似模型的 GTS 模型低风阻尾板优化

胡兴军<sup>1,2</sup> 刘一尘<sup>1</sup> 李金成<sup>1</sup> 兰巍<sup>1</sup> 张扬辉<sup>1</sup> 王靖宇<sup>1†</sup>

(1. 吉林大学 汽车仿真与控制国家重点实验室, 吉林 长春 130012; 2. 吉林大学 汽车工程学院, 吉林 长春 130012)

**摘 要:** 为解决静态近似模型所需样本量大、优化效率低的问题, 基于粒子群算法 (PSO) 的最小二乘支持向量回归 (LSSVR) 自适应近似模型构建优化算法, 并通过构建全局和局部自适应近似模型以减小优化算法陷入局部最优解的可能, 加速收敛过程。文中将 Branin 函数作为测试函数, 证明构建的自适应 PSO-LSSVR 近似模型用于单目标优化问题的有效性; 将自适应 PSO-LSSVR 近似模型用于 GTS 模型低风阻尾板的快速优化上, 以上尾板倾角、下尾板倾角、侧尾板倾角和尾板长度为设计变量, 仅通过 31 组数据集样本便收敛至最优解, 且近似模型预测气动阻力系数误差仅为 0.18%。相比初始尾板, 优化后的尾板使得 GTS 模型气动阻力下降 9.38%, 证明了自适应 PSO-LSSVR 近似模型优化算法对小样本快速寻优问题具有较好的可行性。

**关键词:** GTS 模型; 气动减阻; 自适应近似模型; PSO-LSSVR 算法

**中图分类号:** U461.1

**文章编号:** 1000-565X(2021)05-0038-09

随着能源问题的不断凸显, 商用车因其能耗较高、受空气阻力影响大的特点, 逐渐成为气动减阻领域的研究热点。Hakansson<sup>[1]</sup>通过改变重型卡车货箱外形及增加各种气动附加装置, 发现合理布置的气动附加装置可以达到与流线型货箱同等的气动减阻效果, 而并不压缩货箱容积, 从而说明了气动附加装置的重要性。其中, 尾板由于形状简单、容易布置, 且减阻潜能大而获得了广泛关注。Salati 等<sup>[2]</sup>通过对某汽车列车梯形尾板及圆锥形气动附加装置进行研究和优化, 发现当梯形尾板倾角为 13°时, 汽车列车气动阻力系数随着梯形尾板的板长增加呈现出先增加后降低的趋势; Ellis 等<sup>[3]</sup>通过在尾板中间增加副尾板, 使得某汽车列车在 0°~5°偏航角的平均气动阻力系数降低最高达 26%; Hassaan 等<sup>[4]</sup>基于无车轮 GTS 模型增加尾板结构, 并以尾板长度和倾角作为变量探究最优阻力方案减

阻机理, 发现尾板越长气动阻力系数越小, 倾角为 15°时气动阻力系数最小, 并指出 C 柱涡引起的上洗气流变化是控制尾部上洗涡、下洗涡分布的关键因素; 国内的胡兴军等<sup>[5]</sup>通过对比 5 种不同的尾板方案指出, 推迟气流分离的尾板方案相比产生分离涡的尾板方案可以获得更大的气动减阻效果。

另一方面, 气动减阻中的试验设计 (DOE) 和优化也是研究重点。张凯歌<sup>[6]</sup>通过使用静态 SVR (支持向量回归) 近似模型, 对重型卡车尾板进行优化, 取得了气动减阻 8.2% 的成果; Doyle 等<sup>[7]</sup>应用遗传算法 (GA) 直接驱动 CFD 程序, 从而实现二维卡车尾板几何的自动寻优, 但其执行的 GA 算法相当于每次产生 300 个样本点, 对于计算量巨大的三维流场仿真很难应用。总体来讲, 先构建静态近似模型, 再利用某种寻优算法对近似模型进行寻优获得最优点是优化设计的常见思路。但

收稿日期: 2020-08-10  
基金项目: 国家自然科学基金资助项目 (51875238)  
Foundation item: Supported by the National Natural Science Foundation of China (51875238)  
作者简介: 胡兴军 (1976-), 男, 教授, 博士生导师, 主要从事汽车空气动力学研究。E-mail: hxj@jlu.edu.cn  
† 通信作者: 王靖宇 (1976-), 男, 博士, 副教授, 主要从事汽车空气动力学研究。E-mail: wangjy@jlu.edu.cn

是，静态近似模型主要依靠较多的样本点以实现全局拟合精度，存在数据集获取时间长、优化效率低、样本量计算困难的问题。因此，部分学者转而研究追求最优点拟合精度的自适应近似模型。Je-yasingham 等<sup>[8]</sup>利用 ExaADAPT 构建自适应采样法，结合 RSM（响应面方法）近似模型对某皮卡车型的 30 个参数进行了气动减阻优化研究，发现该自适应方法可以加速 RSM 近似模型的收敛过程，并获得预测精度更高的 RSM 近似模型；Huang 等<sup>[9]</sup>通过构建自适应 SVR 近似模型对 T 型管液压成型加载路径进行优化，自适应 SVR 近似模型只迭代 27 次便收敛得到 Pareto 前沿。由此说明自适应近似模型具有较大的优化效率。

本文使用粒子群算法（PSO）完成最小二乘支持向量回归（LSSVR）模型的调参过程，构建自适应 PSO-LSSVR 近似模型，并采用全局和局部自适应近似模型的方式进一步提高最优解区域的拟合精度，尽量避免陷入局部最优解，同时基于 Branin 函数为测试函数进行验证；最后将自适应 PSO-LSSVR 近似模型用于 GTS 模型低风阻尾板的优化设计上。

## 1 自适应 PSO-LSSVR 近似模型的建立

### 1.1 LSSVR 算法

LSSVR 算法是将 SVR 中求解二次规划的问题转换为求解线性方程组的问题，由此可以显著加快收敛速度<sup>[10]</sup>，算法过程如下。

对于训练集  $S = (\mathbf{x}_i, y_i), i = 1, 2, \dots, n$ ，其中  $\mathbf{x}_i \in \mathbf{R}^m$ ，作为训练集的  $m$  维输入； $y_i \in \mathbf{R}$ ，作为一维输出。在 SVR 中，将原样本空间中的非线性函数估计问题转化为高维特征空间的线性函数估计问题的表达式如下：

$$\tilde{f}(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\varphi}(\mathbf{x}) + b \quad (1)$$

式中： $\mathbf{w} = (w_1, w_2, \dots, w_n)^T$ ，为权值系数向量； $\boldsymbol{\varphi}(\mathbf{x}) = (\varphi_1(\mathbf{x}), \dots, \varphi_n(\mathbf{x}))^T$ ，为输入映射函数； $b$  为实常量。利用结构风险最小化原理求解，将问题转换为一个等式约束优化问题：

$$\min J(\mathbf{w}, \mathbf{e}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \frac{\gamma}{2} \sum_{i=1}^n e_i^2 \quad (2)$$

$$\text{s. t. } y_i = \mathbf{w}^T \boldsymbol{\varphi}(\mathbf{x}_i) + b + e_i, \quad i = 1, 2, \dots, n.$$

式中， $\gamma$  为正则化系数， $e_i$  为误差项，可在后式中约去。求解上述优化问题，使用 Lagrange 等式并根据 KKT 条件得：

$$\begin{bmatrix} 0 & \mathbf{1}_n^T \\ \mathbf{1}_n & \Omega + \frac{1}{\gamma} \mathbf{E}_n \end{bmatrix} \begin{bmatrix} b \\ \boldsymbol{\alpha} \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{y} \end{bmatrix} \quad (3)$$

式中， $\mathbf{E}_n$  为  $n$  阶单位矩阵， $\mathbf{1}_n = (1, 1, \dots, 1)^T$ ， $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ ， $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$ ， $\alpha_i$  是拉格朗日乘子， $\Omega = k(\mathbf{x}_i, \mathbf{x}_j)$ ， $k(\mathbf{x}_i, \mathbf{x}_j) = \boldsymbol{\varphi}^T(\mathbf{x}_i) \boldsymbol{\varphi}(\mathbf{x}_j)$ ， $i, j = 1, 2, \dots, n$ 。求解  $\boldsymbol{\alpha}$  和  $b$  后，LSSVR 算法可以表述为

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i) + b \quad (4)$$

为了避免“维数灾难”问题，LSSVR 引入了核函数<sup>[11]</sup>。常用的核函数包括线性核函数、多项式核函数、RBF 核函数及 Sigmoid 核函数等。RBF 核函数具有普适性强的特点，可以适用于任意分布的样本集<sup>[12]</sup>，因此本文构建的 LSSVR 模型采用 RBF 核函数。RBF 核函数表达式如下：

$$k(\mathbf{x}, \mathbf{x}_i) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}_i\|^2}{2\sigma^2}\right) \quad (5)$$

式中， $\sigma$  为核函数的宽度。本文的 LSSVR 模型使用 MATLAB LSSVM Toolbox V1.6 构建，在该工具箱中，LSSVR 模型的  $\sigma^2$  和  $\Gamma$ （惩罚因子）决定拟合和泛化能力。已有的文献采用交叉验证法<sup>[12]</sup>、网格搜索法<sup>[13]</sup>、核校准<sup>[14]</sup>等方法进行调参，本文针对上述两个参数，构建二维坐标  $(\sigma^2, \Gamma)$ ，采用 PSO 进行自适应调参。

### 1.2 PSO-LSSVR 近似模型构建方法

PSO 算法是一种全局优化的进化算法<sup>[15]</sup>，因其具有相对较高的求解效率和较快的收敛速度，被广泛用于模型调参、函数优化等领域。

PSO 算法的原理是采用一种仅有速度和位置两个属性的粒子来模拟鸟类觅食的过程，其更新速度和位置的公式如下：

$$\mathbf{v}_{i+1} = \omega \mathbf{v}_i + c_1(\mathbf{p}_{\text{best},i} - \mathbf{x}_i) + c_2(\mathbf{g}_{\text{best},i} - \mathbf{x}_i) \quad (6)$$

$$\mathbf{x}_{i+1} = \mathbf{x}_i + \mathbf{v}_{i+1} \quad (7)$$

式中： $i$  为迭代次数； $\mathbf{v}_i$  为粒子第  $i$  次迭代的速度向量； $\mathbf{x}_i$  是粒子第  $i$  次迭代的位置向量； $\mathbf{p}_{\text{best},i}$  是粒子历史最优解的位置向量； $\mathbf{g}_{\text{best},i}$  是粒子群当前最优解的位置向量； $\omega$  是惯性系数，用于调整全局寻优与局部寻优能力，一般取 0 至 1 之间； $c_1$  和  $c_2$  被分别称为每个粒子的个体学习因子和社会学习因子，通常取  $c_1 = c_2 = 2$ 。

均方根误差（RMSE）因其量纲与数据集相同，更加便于解释误差，因此本文使用验证集的 RMSE 作为 PSO 算法的适应度函数。RMSE 的计算

表达式如下：

$$\text{RMSE} = \sqrt{\frac{1}{M} \sum_{k=1}^M (y_k - \tilde{y}_k)^2}$$

(8)

式中， $M$  为验证集样本总数， $y_k$  为第  $k$  个验证集样本的真值， $\tilde{y}_k$  为第  $k$  个验证集样本的预测值。本文构建的 PSO-LSSVR 近似模型步骤如图 1 所示。

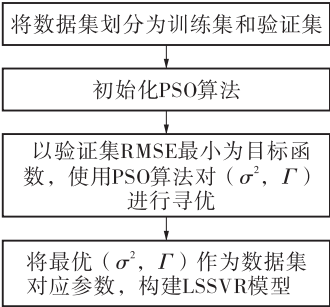


图1 PSO-LSSVR 近似模型构建方法

Fig. 1 Method of PSO-LSSVR approximation method

1.3 自适应 PSO-LSSVR 近似模型构建方法

在自适应近似模型构建中，未达到收敛标准之前，每次迭代产生的解将会被重新放入数据集中，这些解被称为校正点。校正点的选取对模型拟合效果有很大影响，目前较为常见的思路是响应最优策略<sup>[9]</sup>，即将每次迭代的最优解作为校正点，但 Jones 等<sup>[16]</sup>指出响应最优策略容易使得近似模型陷入局部最优解。

另一方面，在利用 PSO 算法进行 LSSVR 模型的调参时，将会根据验证集数据 RMSE 选择最佳超参数。如果验证集是每次迭代后的数据集最优解时，理论上可以获得在数据集最优解处拟合精度最高的近似模型，从而加快寻优速度；但如果数据集的最优解不是全局最优解，则更容易陷入局部最优。

综上，为尽量避免自适应 PSO-LSSVR 近似模型陷入局部最优解，本文提出一种自适应近似模型构建方法。借鉴逐步缩减求解域<sup>[17]</sup>的方法，将近似模型分为全局自适应近似模型和局部自适应近似模型两部分，其中全局自适应近似模型的主要目的是较为精确地获得全局最优解的可能位置和数值，为局部自适应近似模型提供边界条件；局部自适应近似模型利用全局自适应近似模型迭代的所有校正点，在全局最优解可能的位置处构建新的自适应近似模型，从而增加全局最优解附近的拟合精度。这样，由于不直接将全局自适应近似模型的最终迭代解作为全局最优解，也就减小了陷入局部最优解的可能，而构建局部自适应近似模型的样本点主要来自以往的校正点，从而加强了样本点的利用率。

同时，为了增强自适应近似模型在最优解附近的搜索能力，自适应近似模型的验证集将从上次迭代预测的最优解实际值和数据集最优解中随机选择，为了保证收敛结果有意义，同一验证集选择方案必须至少保持两次迭代步。全局和局部校正点的收敛标准如下<sup>[18]</sup>：

$$\varepsilon_1 \geq \max \left( \frac{|y_i - y_{i-1}|}{y_{i-1}}, \frac{|\tilde{y}_i - y_i|}{y_i} \right)$$

(9)

$$\varepsilon_2 \geq \max \left( \frac{|y_j - y_{j-1}|}{y_{j-1}}, \frac{|\tilde{y}_j - y_j|}{y_j} \right)$$

(10)

式中： $i$ 、 $j$  分别为全局和局部迭代步； $\varepsilon_1$ 、 $\varepsilon_2$  分别为全局和局部迭代容差； $\tilde{y}$ 、 $y$  分别为自适应模型的预测值和实际值。

1.4 优化问题求解策略

自适应 PSO-LSSVR 近似模型针对单目标优化问题的求解策略如图 2 所示。

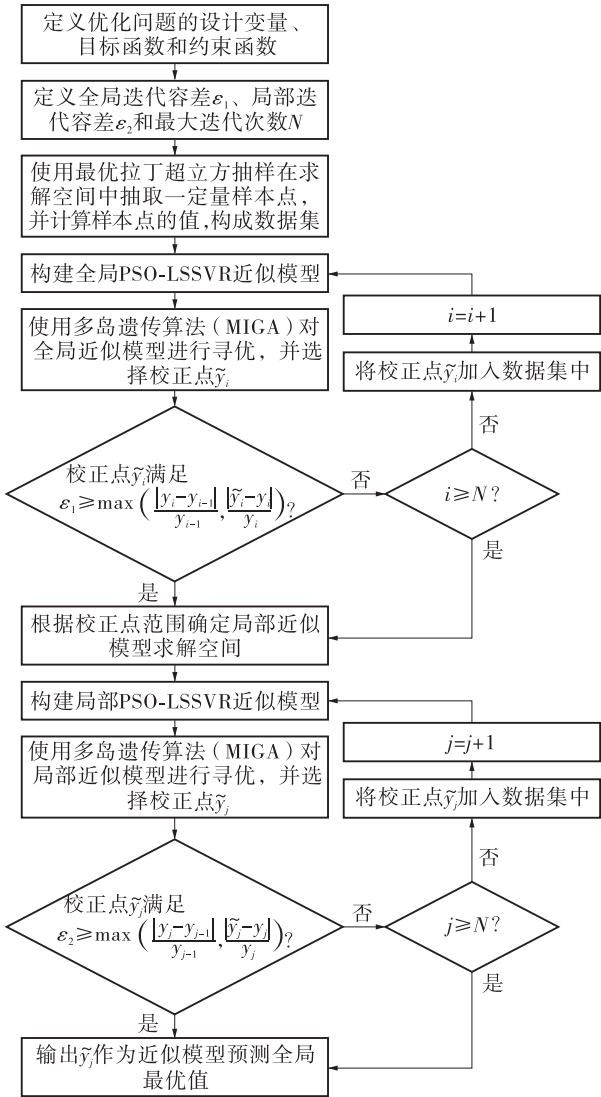


图2 自适应 PSO-LSSVR 近似模型构建方法

Fig. 2 Method of adaptive PSO-LSSVR approximation models



1.5 自适应 PSO-LSSVR 近似模型寻优算例

1.5.1 测试函数

为验证自适应 PSO-LSSVR 近似模型的有效性,使用 Branin 函数<sup>[19]</sup>作为单目标优化问题测试函数,并使用自适应 PSO-LSSVR 近似模型进行全局寻优。

Branin 函数表达式如下:

$$f_{\text{BF}}(x_1,x_2)=\left(x_2-\frac{5.1}{4\pi^2}x_1^2+\frac{5}{\pi}x_1-6\right)^2+10\left(1-\frac{1}{8\pi}\right)\cos x_1+10$$

(11)

其中,  $x_1 \in [-5, 10]$ ,  $x_2 \in [0, 15]$ , 目标函数为  $\min f_{\text{BF}}(x_1, x_2)$ 。该函数理论最优解约为 0.397 887, 具有 3 个最优点。

初始全局数据集选取 20 组样本点, 为兼顾训练和验证效果, 初始验证集为数据集中函数值最小的两组样本点。MIGA 算法个体数为 6 000。

1.5.2 Branin 函数寻优过程

对初始数据集构建自适应 PSO-LSSVR 近似模型。取  $\varepsilon_1 = 5\%$ ,  $\varepsilon_2 = 1\%$ ,  $N = 20$ 。迭代 13 次后, 全局自适应 PSO-LSSVR 近似模型收敛, 进入局部近似模型阶段, 迭代 3 次后, 局部自适应 PSO-LSSVR 近似模型收敛。

自适应 PSO-LSSVR 近似模型在 Branin 函数上的校正点迭代过程如图 3 所示。

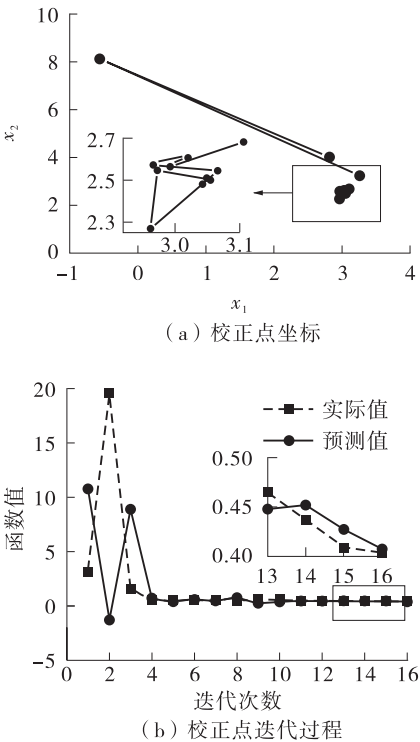


图3 Branin 函数自适应寻优过程

Fig.3 Adaptive optimization process of the Branin function

通过计算 36 组样本点, 最终得到全局最优解为 0.403 665, 位于  $[3.109, 2.331]$  处, 与函数位于  $[\pi, 2.275]$  处的实际全局最优解十分接近, 且该最优点处模型预测值与实际函数值误差仅为 0.92%, 说明构建的自适应 PSO-LSSVR 近似模型成功得到了 Branin 函数的全局最优解。

1.5.3 与其他常用近似模型寻优的对比

为进一步说明自适应 PSO-LSSVR 近似模型相对于其他常用近似模型的优势, 在 Branin 函数的基础上, 分别使用与自适应 PSO-LSSVR 近似模型收敛后相等的样本点数量, 采用 iSight 软件构建静态二阶近似模型 (2 阶 RSM)、三阶 RSM 近似模型 (3 阶 RSM)、静态 Kriging 近似模型和静态 RBF 神经网络近似模型 (静态 RBF NN), 并使用相同参数的 MIGA 算法进行全局寻优, 从而对比得到的最优值及其精度差异。各近似模型在 Branin 函数上的寻优结果如表 1 所示。

表1 各近似模型在 Branin 函数上的寻优结果<sup>1)</sup>

Table 1 Optimization results in Branin function with different approximation models

近似模型	$x_1$	$x_2$	$f_{\text{预测}}$	$f_{\text{实际}}$	预测 误差/%
实际值	9.42	2.48		0.3979	
	-3.14	12.28		0.3979	
	3.14	2.28		0.3979	
2 阶 RSM	9.983	0.109	-33.003	10.135	425.62
3 阶 RSM	9.993	0.113	-77.536	10.213	859.17
静态 Kriging	-3.062	12.241	-0.907	0.452	300.55
静态 RBF NN	9.984	3.108	-12.001	1.873	740.75
PSO-LSSVR	3.109	2.331	0.407	0.404	0.92

1)  $f_{\text{预测}}$  和  $f_{\text{实际}}$  分别为函数的预测值和实际值。

综上所述, 自适应 PSO-LSSVR 近似模型在同等样本量情况下可以获得更优秀的寻优能力及预测效果, 证明其较适合由于样本量获得较为困难而产生的小样本优化问题。本文将应用自适应 PSO-LSSVR 近似模型对 GTS 模型低风阻尾板进行优化设计。

2 GTS 模型低风阻尾板优化

2.1 GTS 模型的计算设置及对标过程

本文采用 GTS 模型作为车辆研究对象。GTS 模型是 Sandia National Laboratories Ground Transportation System 的基础车辆模型<sup>[20]</sup>, 车辆外形是一种具有货箱的半挂汽车列车, 车辆长 19.805 m、宽

2. 590 m、高 4. 113 m。Gutierrez 等<sup>[20-21]</sup>对 1 : 8 GTS 模型进行了风洞试验, 试验结果显示, 非侧风工况时, 车辆尾部流场呈现出几乎对称分布的流场结构。由于本文仅计算非侧风工况稳态情况, 为减少计算量, 可认为流场左右对称分布, 而只计算半车身。

计算域方案参照 SAE J2966 - 2017 标准<sup>[22]</sup>, 为减少计算域宽度对流场的影响, 在推荐值基础上增加至 15 倍半车宽, 计算域全长 220. 0 m (前 3 倍车长、后 7 倍车长)、宽 19. 6 m (15 倍半车宽)、高 24. 0 m (6 倍车高), 阻塞比为 1. 06%。设置 3 层加密区, 按照 1 : 2 增长率逐层加密, 并对车尾分离区进行了再次加密。多面体网格具有生成与计算效率高、对梯度及局部流动分布预测性好的特点<sup>[23]</sup>, 因此本文使用多面体网格进行划分, 网格划分如图 4 所示。




图 4 GTS 模型网格划分  
Fig. 4 Grid configuration of GTS model

数值计算使用 STAR-CCM + 软件。采用 RANS 稳态计算方式和 SST  $k-\omega$  湍流模型进行数值计算, 整车边界层厚度为 2. 16 mm, 划分为 15 层, 使得全车绝大部分满足  $y^+ \leq 1$  的要求, 而仅在驾驶室侧部边缘处, 由于气流加速使得此处  $y^+ \sim 4$ , 为缩小可能带来的计算误差, 使用全  $y^+$  壁面处理功能<sup>[1]</sup>。残差收敛标准为  $10^{-4}$ , 气动阻力系数  $C_D$  收敛后取后 300 步  $C_D$  均值作为最终  $C_D$  计算值。各边界条件如表 2 所示。

表 2 GTS 模型仿真边界条件

Table 2 Boundary condition of simulation of GTS model	
边界条件	参数描述
入口条件	速度入口, 来流速度 27. 78m/s, 湍流度 0. 5%
出口条件	压力出口, 压力 0Pa, 湍流度 1%
对称面条件	对称壁面
地面条件	滑移壁面
壁面条件	对称壁面

Gutierrez 等<sup>[20-21]</sup>的试验雷诺数 (以车宽作为特征长度) 为  $1. 6 \times 10^6$ , 满足商用车缩比模型风

洞试验雷诺数应大于  $0. 5 \times 10^6$  的要求<sup>[24]</sup>, 可认为进入雷诺数自准区, 气动阻力系数不再改变, 这与 Storms 等<sup>[25]</sup>的试验结果变化趋势一致, 因此可用于气动阻力系数对标过程。网格无关性结果与试验的对标结果如表 3 所示。

表 3 气动阻力系数试验对标结果与网格无关性  
Table 3 Benchmark of  $C_D$  and grid independency

网格	体网格数	$C_D$	$\Delta C_D / \% ^{1)}$	误差 / %
试验值 <sup>[21]</sup>		0. 3530		
网格 1	240 万	0. 4375		23. 79
网格 2	469 万	0. 4081	-6. 64	15. 58
网格 3	857 万	0. 3680	-9. 80	4. 25
网格 4	1560 万	0. 3673	-0. 27	3. 96

1)  $\Delta C_D$  指  $C_D$  的相对变化量。

由表 3 可以发现, 当半车身体网格数为 857 万时, 气动阻力系数几乎不变, 且与试验值的误差小于 5%, 而进一步增加体网格数使得计算量增长巨大, 因此使用 857 万网格方案进行后续计算。

2. 2 GTS 模型低风阻尾板的自适应优化过程

对 GTS 模型增加尾板, 并通过自适应 PSO-LSSVR 近似模型研究最优尾板设计。初始方案尾板形状及几何参数如图 5 所示。




图 5 GTS 模型尾板设计变量及初始值  
Fig. 5 Boat-tails design variables and their origin values of GTS model

使用相同的仿真策略, 得到增加尾板后 GTS 模型的气动阻力系数为 0. 3123, 相比无尾板 GTS 模型下降 15. 14%。确定上尾板倾角  $\theta_1$ 、下尾板倾角  $\theta_2$ 、侧尾板倾角  $\theta_3$  和尾板长度  $L$  作为设计变量。由于改型前后车辆正投影面积不变, 故可将气动阻力系数作为目标函数。

根据后扰流器的设计准则<sup>[6]</sup>, 尾板的长度应满足下式:

$$\gamma' = L / \sqrt{A}$$

(12)

式中,  $A$  为商用车的正投影面积,  $\gamma'$  为比例系数, 通常取 0. 28 ~ 0. 57。计算可得尾板的长度范围为

885 ~ 1805 mm。然而在一定情况下，尾板过长不利于侧风稳定，因此选择长度约束条件为 500 ~ 1000 mm，尾板各角度的约束条件均为 5° ~ 20°。整个优化问题描述可以表达为

$$\min f(\theta_1, \theta_2, \theta_3, L)$$
$$\text{s. t. } \theta_1, \theta_2, \theta_3 \in [5, 20],$$
$$L \in [500, 1000].$$

(13)

使用最优拉丁超立方抽样方法对样本空间进行抽样。初始数据集为 22 组样本点，由于数据集因变量  $C_D$  极差只有 0.06 左右，与各自变量极差相差过大，因此对数据集进行归一化以提升 LSSVR 算法训练效率<sup>[26]</sup>。归一化算法如下：

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

(14)

其中， $X = (\theta_1, \theta_2, \theta_3, L, C_D)$ 。

对初始数据集构建自适应 PSO-LSSVR 近似模型。为更加贴近实际优化需求，使用反归一化的气动阻力系数控制收敛过程，并取  $\varepsilon_1 = 1\%$ ， $\varepsilon_2 = 0.5\%$ ， $N = 20$ 。初始化近似模型验证集为 2 组样本点。

迭代 6 次后全局自适应 PSO-LSSVR 近似模型收敛，最优结果范围缩小至  $\theta_{1,\text{norm}} \in [0.191, 0.572]$ ， $\theta_{2,\text{norm}} \in [0.030, 0.296]$ ， $\theta_{3,\text{norm}} \in [0.020, 0.273]$ ， $L_{\text{norm}} \in [0.939, 1.000]$ ，下标 norm 表示归一化后。迭代 3 次后局部自适应 PSO-LSSVR 近似模型收敛。迭代过程如图 6 所示。




图6 气动阻力系数自适应寻优过程

最优气动阻力系数为  $C_{D,\text{norm}} = -0.0184$ ，位于  $\theta_{1,\text{norm}} = 0.5233$ 、 $\theta_{2,\text{norm}} = 0.2784$ 、 $\theta_{3,\text{norm}} = 0.2167$ 、 $L_{\text{norm}} = 0.9766$  处。反归一化结果为  $C_D = 0.2825$ ，位于  $\theta_1 = 12.85^\circ$ 、 $\theta_2 = 9.18^\circ$ 、 $\theta_3 = 8.25^\circ$ 、 $L = 988.31\text{ mm}$  处。计算得到该方案的气动阻力系数为 0.2830，自适应近似模型预测误差仅为 0.18%，

证明了构建的自适应 PSO-LSSVR 近似模型可以用于 GTS 模型低气动阻力尾板的优化。

2.3 最优低风阻尾板减阻机理

相对于初始尾板工况，最优尾板工况气动阻力系数下降达 9.38%。由图 7、图 8 压力系数分布可知，相比于初始方案，优化后方案在尾板附近流场压力出现回升，由图 9 可知，优化后车尾表面压力系数明显提高；由图 10 可以发现，优化后方案的

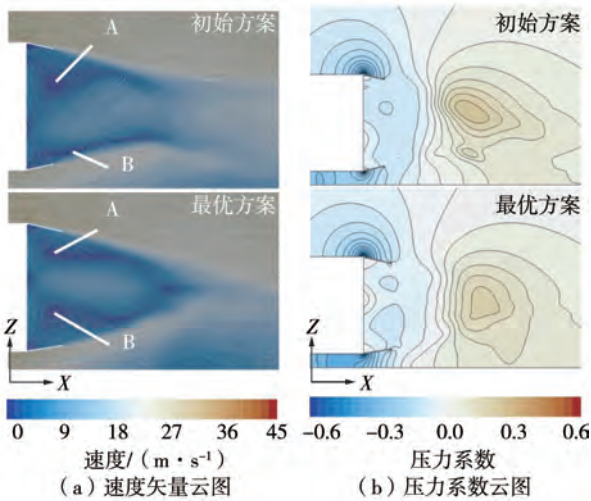


图7 对称面速度矢量及压力系数分布  
Fig. 7 Velocity and pressure coefficient distribution on symmetric plane




图8 Z = 2.3 m 处的速度矢量及压力系数分布  
Fig. 8 Velocity and pressure coefficient distribution on Z = 2.3 m plane






图 9 车尾表面压力系数分布

Fig. 9 Pressure coefficient distribution on the rear surface




图 10 总压为零等值面

Fig. 10 Isosurface of total pressure is zero

总压为零等值面缩小,说明分离区减小,从而降低了压差阻力。观察图 7、图 8 的速度矢量分布,优化后的尾板使得 C 柱下洗气流强度减弱,使得上洗气流得到充分发展,上洗涡(B 涡)更靠近车尾,下洗涡(A 涡)和上洗涡(B 涡)呈现出对称分布的特点,驻点上移,使得尾部分离区面积减小,侧板附近的分离涡(C 涡)尺度减小。优化后方案的对称面尾流场分布,与 Hassaan 等<sup>[4]</sup>对无车轮 GTS 模型尾板研究中相似板长最低阻力工况的尾流场分布类似。图 11 是使用  $\lambda_2$  涡识别方法得到的尾流分离区涡分布图,可以看出,由于上洗气流强度的减弱,优化后流向涡尺度明显减小,且位置不再紧贴地面。

3 结论

(1) 通过合理选择初始数据集样本量和验证集,基于 PSO-LSSVR 机器学习算法的自适应近似

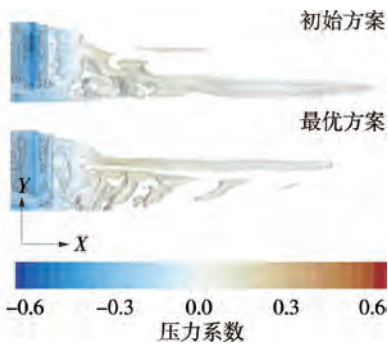


图 11  $\lambda_2 = -5$  等值面  
Fig. 11 Isosurface of  $\lambda_2 = -5$

模型在数据集样本量一定的情况下,于 Branin 函数上的寻优能力和拟合精度超过了常用的 4 种近似模型,说明自适应 PSO-LSSVR 近似模型优化方法具有较大的快速寻优潜力。

(2) 自适应 PSO-LSSVR 近似模型可以通过对最优解构建局部近似模型的方法,增强模型在最优解处的拟合精度。

(3) 将自适应 PSO-LSSVR 近似模型优化方法应用在 GTS 模型低风阻尾板优化上,仅使用 31 组样本便得出了最优方案,最优方案相比初始方案减阻达 9.38%,且局部近似模型拟合误差仅为 0.18%。由此说明自适应 PSO-LSSVR 近似模型优化方法在保证寻优精度的情况下,寻优效率提升明显,适用于单样本点获取耗时较多的小样本单目标优化问题。

参考文献:

[1] HAKANSSON C. CFD analysis of aerodynamic trailer devices for drag reduction of heavy duty trucks [D]. Gothenburg: Chalmers University of Technology, 2010.

[2] SALATI L, CHELI F, SCHITO P. Heavytruck drag reduction obtained from devices installed on the trailer [J]. SAE International Journal of Commercial Vehicles, 2015, 8(2): 747-760.

[3] ELLIS M, GARGOLOFF J I, SENGUPTA R. Aerodynamic drag and engine cooling effects on Class 8 trucks in platooning configurations [J]. SAE International Journal of Commercial Vehicles, 2015, 8(2): 732-739.

[4] HASSAAN M, BADLANI D, NAZARINIA M. On the effect of boat-tails on a simplified heavy vehicle geometry under crosswinds [J]. Journal of Wind Engineering & Industrial Aerodynamics, 2018(183): 172-186.

- [5] 胡兴军, 李腾飞, 王靖宇, 等. 尾板对重型载货汽车尾部流场的影响 [J]. 吉林大学学报 (工学版), 2013, 43(3): 595-601.  
HU Xingjun, LI Tengfei, WANG Jingyu, et al. Numerical simulation of the influence of rear-end panels on the wake flow field of a heavy-duty truck [J]. Journal of Jilin University (Engineering and Technology Edition), 2013, 43(3): 595-601.
- [6] 张凯歌. 重型卡车气动性能优化与实验研究 [D]. 长沙: 湖南大学, 2016.
- [7] DOYLE J, HARFIELD R, ROY C. Aerodynamic optimization for freight trucks using a genetic algorithm and CFD [C] // Proceedings of the 46th AIAA Aerospace Sciences Meeting and Exhibit. Reno: AIAA, 2008: 1-20.
- [8] JEYASINGHAM S, SRINIVASAN K. Detailed aerodynamic characterization and optimization of a pickup truck using adaptive sampling based DOE [J]. SAE Technical Papers, 2018, 2018: 1-7.
- [9] HUANG T, SONG X, Liu M. The multi-objective optimization of the loading paths for T-shape tube hydroforming using adaptive support vector regression [J]. The International Journal of Advanced Manufacturing Technology, 2017, 88(9/10/11/12): 3447-3458.
- [10] SUYKENS J A K, VANDEWALLE J. Least squares support vector machine classifiers [J]. Neural Processing Letters, 1999, 9(3): 293-300.
- [11] DENG N, TIAN Y, ZHANG C. Support vector machines: optimization based theory, algorithm, and extensions [M]. Boca Raton: CRC Press, 2012: 20-38.
- [12] 刘苏苏, 孙立民. 支持向量机与 RBF 神经网络回归性能比较研究 [J]. 计算机工程与设计, 2011, 32(12): 4202-4205.  
LIU Susu, SUN Limin. Performance comparison of regression prediction on support vector machine and RBF neural network [J]. Computer Engineering and Design, 2011, 32(12): 4202-4205.
- [13] 张春, 岳森. 基于最小二乘支持向量机的耕地面积变化预测模型 [J]. 现代工业经济和信息化, 2013(2): 72-74.  
ZHANG Chun, YUE Sen. Prediction of cultivated land change based on least squares support vector machine [J]. Modern Industrial Economy and Informationization, 2013(2): 72-74.
- [14] CRISTIANINI N, KANDOLA J, ELISSE Eff A, et al. On kernel target alignment [J]. Innovations in Machine Learning, 2006, 194: 208-209.
- [15] VENTER G, JAROSLAW S S. Particle swarm optimization [J]. AIAA Journal, 2003, 41(8): 129-132.
- [16] JONES D R, SCHONLAU M, WELCH W J. Efficient global optimization of expensive black-box function [J]. Journal of Global Optimization, 1998, 13(4): 445-492.
- [17] WANG G G. Adaptive response surface method using inherited Latin hypercube design points [J]. Journal of Mechanical Design, 2003, 125(2): 210-220.
- [18] 宋学伟, 李东营, 黄天仑. T 型管液压成形加载路径自适应多目标优化 [J]. 哈尔滨工业大学学报, 2017, 49(7): 139-145.  
SONG Xuewei, LI Dongying, HUANG Tianlun. Multi-objective optimization for T-shaped tube hydroforming process design [J]. Journal of Harbin Institute of Technology, 2017, 49(7): 139-145.
- [19] WANG G G, DONG Z, AITCHISON P. Adaptive response surface method-A global optimization scheme for approximation-based design problems [J]. Engineering Optimization, 2001, 33(6): 707-734.
- [20] GUTIERREZ W T, HASSAN B, CROLL R H, et al. Aerodynamics overview of the ground transportation systems (GTS) project for heavy vehicle drag reduction [J]. SAE Special Publications, 1996 (1145): 219.
- [21] CROLL R H, GUTIERREZ W T, HASSAN B, et al. Experimental investigation of the ground transportation systems (GTS) project for heavy vehicle drag reduction [J]. SAE Special Publications, 1996 (1145): 237.
- [22] Guidelines for aerodynamic assessment of medium and heavy commercial ground vehicles using computational fluid: SAE J2966—2017 [S].
- [23] 许晓平, 周洲. 多面体网格在 CFD 中的应用 [J]. 飞行力学, 2009, 27(6): 87-89.  
XU Xiaoping, ZHOU Zhou. Application of polyhedral mesh in CFD [J]. Flight Dynamics, 2009, 27(6): 87-89.
- [24] 杜广生. 厢式货车空气动力学特性的研究 [D]. 无锡: 中国船舶科学研究中心, 2002.
- [25] STORMS B L, ROSS J C, HEINECK J T, et al. An experimental study of the ground transportation system (GTS) model in the NASA ames 7-by-10-ft wind tunnel [R]. Hanover: NASA Center for AeroSpace Information, 2001: 1-21.
- [26] 汤荣志. 数据归一化方法对提升 SVM 训练效率的研究 [D]. 济南: 山东师范大学, 2017.



# Optimization for Low Aerodynamic Drag Boat-Tail of GTS Model Based on Adaptive Approximation Model

HU Xingjun<sup>1,2</sup> LIU Yichen<sup>1</sup> LI Jincheng<sup>1</sup> LAN Wei<sup>1</sup> ZHANG Yanghui<sup>1</sup> WANG Jingyu<sup>1</sup>

- (1. State Key Laboratory of Automotive Simulation and Control, Jilin University, Changchun 130012, Jilin, China;
- 2. College of Automotive Engineering, Jilin University, Changchun 130012, Jilin, China)

**Abstract:** To solve the problems of large sample size and low optimization efficiency of static approximation model, the least squares support vector regression (LSSVR) based adaptive approximation model with particle swarm optimization (PSO) algorithm was introduced to construct the optimization algorithm. The global and local adaptive approximation models were constructed to reduce the possibility of the optimization algorithm falling into the local optimal solution and to accelerate the convergence process. The Branin function was used as test function to prove the effectiveness of the proposed adaptive PSO-LSSVR approximation model for single-objective optimization problems. The adaptive PSO-LSSVR approximation model was applied to the rapid optimization of boat-tail of GTS model. The upper boat-tail angle, the lower boat-tail angle, the side boat-tail angle and the tail plate length were taken as design variables, and the optimal solution could be obtained only with 31 sample data sets. And the error of aerodynamic drag coefficient predicted by the approximation model is only 0.18%. The aerodynamic drag of GTS model with optimized boat-tail is reduced by 9.38% after optimization, which proves that the adaptive PSO-LSSVR approximation model optimization method is feasible for fast optimization problem with small samples.

**Key words:** GTS model; aerodynamic drag reduction; adaptive approximation model; PSO-LSSVR algorithm

(上接第 17 页)

# Coupling Thermodynamics Analysis for Ascent Stage of Stratospheric Airship

HAN Qiang<sup>1</sup> TANG Ziqi<sup>1</sup> ZHANG Run<sup>1</sup> LIU Tingting<sup>2</sup> YAO Xiaohu<sup>1</sup>

- (1. School of Civil Engineering and Transportation, South China University of Technology, Guangzhou 510640, Guangdong, China;
- 2. China Special Aircraft Research Institute, Jingmen 448000, Hubei, China)

**Abstract:** A new coupling thermodynamics analysis method based on the ADAMS and MATLAB joint simulation was proposed for ascent stage of stratospheric airship in complex external environment and multi-physical coupling conditions. An accurate thermal-mechanical coupling mathematical model for ascent of airship was built by using MATLAB in this method. Based on this method, the discrete time-domain method and Newton iterative algorithm were used to decouple the model to obtain relevant parameter curves. The model of airship was established in dynamic environment of ADAMS and a CONSUB subroutine which is available to retrieve the variable data of the airship mass in real time was developed. The visualized simulation control for the ascent stage of variable mass stratospheric airship was realized by applying the decoupled load and calling the subroutine. The coupling thermodynamics analysis of a certain stratospheric airship was performed using the above method to obtain the rules of trajectory, attitude and air temperature in air bag. The results show that the design minimum of the pressure difference between the inside and outside of the airbag is not significant for real-time control of airship speed, and the temperature of gas in the air bag rises during the stratosphere stage. The analysis indicates that this method can efficiently and accurately simulate the ascent of stratospheric airship with variable mass under the coupling of complex multi-physical conditions and obtain thermodynamic parameters. This method is of great reference value for the parameter control and optimization design of airship.

**Key words:** stratospheric airship; dynamical model; thermodynamic model; MATLAB; ADAMS variable mass subroutine; coupling thermodynamics analysis